

Diseño arquitectónico mínimo para sistemas RAG observables en español latinoamericano

Nicole Tatiana Parra Valverde · Trabajo independiente

Caso de estudio: normativa estudiantil del Tecnológico de Costa Rica

Registrar evidencia, citas y tiempos permite explicar no solo cuánto falla un RAG, sino en qué componente ocurre el fallo.

Arquitectura mínima = pipeline reproducible + contrato de salida + traza por consulta

Cada componente produce un artefacto verificable y conserva suficiente contexto para atribuir los fallos.



Traza observable por consulta

pregunta → IDs y puntuaciones de fragmentos → contexto → respuesta y estado → citas → tiempos

El corpus, el índice, las preguntas, la configuración y los resultados quedan versionados. Esto permite reproducir la corrida y separar fallos de recuperación, generación y validación.

Configuración: multilingual-e5-small · top-5 · Qwen3.5:9B Q4_K_M · temperatura 0,1 · ejecución local

Problema y objetivo

Los prototipos RAG suelen mostrar una respuesta final, pero no siempre conservan la cadena de evidencia necesaria para explicar por qué fue generada. Sin una traza es difícil distinguir fallos de recuperación, generación o validación.

OBJETIVO

Diseñar e implementar una arquitectura RAG mínima, local y reproducible para documentos en español latinoamericano, con señales básicas de observabilidad por consulta.

Caso de estudio

25 documentos oficiales
1 184 secciones procesadas
1 259 fragmentos indexados

Normativa estudiantil del TEC, Costa Rica. Cada captura conserva URL, fecha y suma de verificación.

Diseño experimental

40 preguntas de referencia

25 directas · 8 de varias secciones · 7 no respondibles

Cada ejecución guardó fragmentos, respuesta, citas y tiempos. Las 40 respuestas se revisaron manualmente con seis criterios.

Revisión humana

- Corrección factual
- Cobertura
- Fidelidad a fuentes
- Claridad
- Evidencia gold
- Conclusión manual

Las métricas automáticas describen recuperación, citas y latencia; no se presentan como exactitud factual.

Resultados

La evaluación humana permite distinguir contenido correcto, cobertura y calidad de la salida.

78,8 %

corrección factual estricta

93,5 %

fidelidad total a fuentes


72,7 %

cobertura completa

7 / 7

abstenciones correctas

Aprobación por tipo de pregunta



Hallazgo central: el sistema se abstiene bien, pero pierde cobertura cuando debe combinar evidencia distribuida.

Rendimiento automático

93,9 % recuperación con evidencia gold en top-5

27 ms búsqueda semántica promedio

5,53 s por pregunta: la generación consume 5,36 s en promedio y domina la latencia del pipeline.

Lo que reveló la observabilidad

1 Evidencia distribuida

Solo 2 de 8 preguntas de varias secciones fueron aprobadas. Con frecuencia se recuperó una parte, pero no todos los artículos necesarios.

2 Documento correcto, fragmento incorrecto

En q029 apareció el artículo relacionado, pero no el fragmento que contenía el dato. El análisis por Record ID habría ocultado el fallo.

3 Contenido correcto, salida inválida

q025 y q032 se rechazaron porque las citas visibles y estructuradas no coincidían. La validez del contrato también es calidad.

4 Abstención confiable

Las 7 preguntas sobre precios, horarios, contraseñas o cupos actuales recibieron not_found, sin inventar información ausente.

CONCLUSIÓN

Una arquitectura pequeña puede ofrecer trazabilidad útil sin una plataforma compleja. Registrar evidencia, citas, estados y tiempos permitió localizar fallos en recuperación, generación y validación.

Limitaciones y trabajo futuro

- Limitaciones
- Un dominio, un embedding y un modelo generativo
 - 40 preguntas y una persona revisora
 - Sin comparación léxica, híbrida ni reranking

- Siguientes pasos
- Reranking para evidencia multisección
 - Comparar recuperación densa, léxica e híbrida
 - Ampliar países, dominios y revisión humana

CÓDIGO, DATOS Y DOCUMENTACIÓN

github.com/niparra21/nlpArgentina