

Diseño arquitectónico mínimo para sistemas RAG observables en español latinoamericano

Nicole Tatiana Parra Valverde

Trabajo independiente

Caso de estudio: normativa estudiantil del Tecnológico de Costa Rica




Fig. 1. Arquitectura RAG mínima y observable. Cada componente produce un artefacto verificable; la traza conserva pregunta, fragmentos, contexto, respuesta, estado, citas y tiempos. Configuración: multilingual-e5-small; top-5; Qwen3.5:9B Q4_K_M; temperatura 0,1; ejecución local.

I. RESUMEN Y OBJETIVO

Resumen—Los prototipos RAG suelen mostrar una respuesta final, pero no siempre conservan la cadena de evidencia necesaria para explicar por qué fue generada. Sin una traza es difícil distinguir fallos de recuperación, generación o validación. El diseño parte del paradigma RAG descrito por Lewis et al. [1].

Objetivo—Diseñar e implementar una arquitectura RAG mínima, local y reproducible para documentos en español latinoamericano, con señales básicas de observabilidad por consulta.

Palabras clave—RAG, PLN en español, recuperación de información, observabilidad, modelos de lenguaje.

II. CASO DE ESTUDIO

25 documentos oficiales
1 184 secciones procesadas
1 259 fragmentos indexados

Normativa estudiantil del TEC, Costa Rica. Cada captura conserva URL, fecha y suma de verificación. El corpus, sus metadatos y el procesamiento están versionados en el repositorio [2].

III. METODOLOGÍA

- Recolección de 25 documentos oficiales.
- Extracción de artículos y disposiciones transitorias.
- Fragmentación con máximo de 480 tokens y solapamiento de 50.
- Embeddings con multilingual-e5-small [3], normalizados a 384 dimensiones.
- Recuperación top-5 por similitud coseno.
- Generación local con Qwen3.5:9B y temperatura 0,1.
- Validación de estado, citas y contrato JSON.

Evaluación: 40 preguntas de referencia: 25 directas, 8 de varias secciones y 7 no respondibles. Cada ejecución guardó fragmentos, respuesta, citas y tiempos.

IV. REVISIÓN HUMANA

Las 40 respuestas se revisaron manualmente con seis criterios:

- corrección factual;
- cobertura;
- fidelidad a fuentes;
- claridad;
- presencia de evidencia gold;
- conclusión manual.

Las métricas automáticas describen recuperación, citas y latencia; no se presentan como exactitud factual.


V. RESULTADOS

La evaluación humana permite distinguir contenido correcto, cobertura de evidencia y validez de la salida.

78,8 % corrección factual estricta
93,5 % fidelidad total a fuentes

72,7 % cobertura completa
7 / 7 abstenciones correctas

VI. APROBACIÓN POR TIPO DE PREGUNTA



Hallazgo central—El sistema se abstiene bien, pero pierde cobertura cuando debe combinar evidencia distribuida.

XII. Referencias

- [1] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W. tau Yih, T. Rocktäschel, S. Riedel, and D. Kiela, “Retrieval-augmented generation for knowledge-intensive nlp tasks,” in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 9459–9474.
- [2] Tecnológico de Costa Rica, “Reglamentos y normativa institucional utilizados como corpus,” Sitio web institucional y captura reproducible del proyecto, 2026, corpus de 25 documentos; consultado y versionado en julio de 2026. [Online]. Available: <https://www.tec.ac.cr/>
- [3] L. Wang, N. Yang, X. Huang, L. Yang, R. Majumder, and F. Wei, “Multilingual e5 text embeddings: A technical report,” *arXiv preprint arXiv:2402.05672*, 2024.

Los resultados corresponden a una corrida reproducible del prototipo y no sustituyen la consulta de la normativa oficial.

VII. RENDIMIENTO AUTOMÁTICO

93,9 % recuperación con evidencia gold en top-5
27 ms búsqueda semántica promedio
5,53 s por pregunta: la generación consume 5,36 s en promedio y domina la latencia del pipeline. La búsqueda representa menos del 1 % del tiempo total.

VIII. INTERPRETACIÓN DE LAS MÉTRICAS

- **Corrección factual estricta:** proporción de respuestas respondibles calificadas como correctas, sin dar crédito a las parciales.
- **Fidelidad total:** grado en que las afirmaciones permanecen apoyadas por los fragmentos recuperados.
- **Cobertura completa:** presencia de toda la evidencia necesaria, no solo de una parte.
- **Recuperación top-5:** localización automática de al menos una evidencia gold entre los cinco primeros fragmentos.

IX. LO QUE REVELÓ LA OBSERVABILIDAD

1) Evidencia distribuida. Solo 2 de 8 preguntas de varias secciones fueron aprobadas. Con frecuencia se recuperó una parte, pero no todos los artículos necesarios.

2) Documento correcto, fragmento incorrecto. En q029 apareció el artículo relacionado, pero no el fragmento que contenía el dato. El análisis por identificador de registro habría ocultado el fallo.

3) Contenido correcto, salida inválida. q025 y q032 se rechazaron porque las citas visibles y estructuradas no coincidían. La validez del contrato también es calidad.

4) Abstención confiable. Las 7 preguntas sobre precios, horarios, contraseñas o cupos actuales recibieron not_found, sin inventar información ausente.

X. CONCLUSIÓN

Una arquitectura pequeña puede ofrecer trazabilidad útil sin una plataforma compleja. Registrar evidencia, citas, estados y tiempos permitió localizar fallos en recuperación, generación y validación.

El prototipo funcionó mejor con preguntas directas y abstenciones. El reto principal fue combinar evidencia distribuida. Por ello, una arquitectura RAG observable debe distinguir evidencia por documento y por fragmento, y validar la consistencia de las citas antes de entregar la respuesta.

XI. LIMITACIONES Y TRABAJO FUTURO

Limitaciones

- un dominio, un embedding y un modelo generativo;
- 40 preguntas y una persona revisora;
- sin comparación léxica, híbrida ni reranking;
- el caso no representa toda la diversidad del español latinoamericano.

Trabajo futuro

- reranking para evidencia multisección;
- comparar recuperación densa, léxica e híbrida;
- ampliar países, dominios y revisión humana;
- estudiar umbrales de abstención y calibración.

CÓDIGO, DATOS Y DOCUMENTACIÓN

Repositorio reproducible:

<https://github.com/niparra21/nlpArgentina>