

Diseño arquitectónico mínimo para sistemas RAG observables en español latinoamericano

Nicole Tatiana Parra Valverde

Trabajo independiente

Caso de estudio: normativa estudiantil del Tecnológico de Costa Rica




Fig. 1. Flujo de indexación del corpus. Los documentos oficiales se transforman en secciones, fragmentos y embeddings normalizados antes de construir el índice vectorial local.

I. INTRODUCCIÓN

Resumen—La generación aumentada por recuperación (RAG) incorpora evidencia externa al contexto de un modelo de lenguaje [1]. Sin embargo, una respuesta final no permite establecer por sí sola si un fallo se originó en la recuperación, la generación o la validación. Este trabajo presenta una arquitectura RAG mínima, local y reproducible para normativa en español latinoamericano. El diseño conserva una traza por consulta y expone los artefactos necesarios para auditar cada resultado.

Contribución—Se implementó un pipeline reproducible que integra indexación documental, recuperación semántica, generación local, validación de citas y observabilidad básica, sin depender de una plataforma de despliegue compleja.

Palabras clave—RAG, PLN en español, recuperación de información, observabilidad, modelos de lenguaje.

II. CORPUS E INDEXACIÓN

25 documentos oficiales **1 184** secciones procesadas **1 259** fragmentos indexados

El caso de estudio comprende normativa estudiantil publicada por el Tecnológico de Costa Rica. Cada captura conserva la URL oficial, la fecha de recolección y una suma SHA-256. El procesamiento produjo 1 141 artículos y 43 disposiciones transitorias. Las secciones de mayor longitud se dividieron con un máximo de 480 tokens y un solapamiento de 50, lo que generó 1 259 fragmentos indexados. El corpus, sus metadatos y el procesamiento se versionaron en el repositorio [2]. La Fig. 1 resume esta ruta de transformación.

III. DISEÑO E IMPLEMENTACIÓN

Los fragmentos se codificaron con `intfloat/multilingual-e5-small` [3]. Cada representación contiene 384 dimensiones y se normalizó antes de almacenarse. Durante la consulta, el orquestador codifica la pregunta, calcula la similitud coseno contra el índice y recupera los cinco fragmentos con mayor puntuación.

El contexto recuperado y la pregunta se envían a Qwen3.5:9B mediante Ollama. La generación se ejecuta localmente con temperatura 0,1 y un contrato JSON que limita el estado a `answered` o `not_found`. Una validación posterior comprueba el estado, el texto y los identificadores de cita antes de presentar la respuesta.

Configuración principal: top-5; similitud coseno; Qwen3.5:9B Q4_K_M; temperatura 0,1; ejecución local.

IV. PROTOCOLO DE EVALUACIÓN

La evaluación utilizó 40 preguntas de referencia: 25 directas, 8 que requieren evidencia de varias secciones y 7 no respondibles con el corpus. Para cada consulta se conservaron los fragmentos recuperados, sus puntuaciones, el contexto, la respuesta, el estado, las citas y los tiempos.

Las respuestas se revisaron manualmente con seis criterios: corrección factual, cobertura, fidelidad a las fuentes, claridad, presencia de evidencia de referencia y conclusión global. Las métricas automáticas se utilizaron para describir recuperación, citas y latencia; no se interpretaron como una medida de exactitud factual.

V. OBSERVABILIDAD POR CONSULTA

Como muestra la Fig. 2, cada ejecución válida produce un registro JSON con cuatro grupos de información. *Configuración* identifica el corpus, el índice, los modelos y sus parámetros. *Recuperación* conserva los fragmentos, los identificadores, el orden, las puntuaciones y la procedencia oficial. *Generación* registra latencia, tokens y características del contexto. *Resultado* incluye el estado, la respuesta, las citas validadas y las fuentes citadas.

La traza se utiliza como un artefacto diagnóstico, no como una métrica de calidad. Su propósito es atribuir un fallo a la etapa que lo produjo y permitir que una ejecución pueda examinarse posteriormente sin repetirla.

CÓDIGO, DATOS Y DOCUMENTACIÓN

Repositorio reproducible:

<https://github.com/niparra21/nlpArgentina>

X. Referencias

- [1] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W. tau Yih, T. Rocktäschel, S. Riedel, and D. Kiela, “Retrieval-augmented generation for knowledge-intensive nlp tasks,” in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 9459–9474.
- [2] Tecnológico de Costa Rica, “Reglamentos y normativa institucional utilizados como corpus,” Sitio web institucional y captura reproducible del proyecto, 2026, corpus de 25 documentos; consultado y versionado en julio de 2026. [Online]. Available: <https://www.tec.ac.cr/>
- [3] L. Wang, N. Yang, X. Huang, L. Yang, R. Majumder, and F. Wei, “Multilingual e5 text embeddings: A technical report,” *arXiv preprint arXiv:2402.05672*, 2024.

Los resultados corresponden a una corrida reproducible del prototipo y no sustituyen la consulta de la normativa oficial.





Fig. 2. Flujo de consulta y generación observables. El orquestador coordina embeddings, recuperación, generación y validación; la traza conserva pregunta, fuentes, respuesta, estado y tiempos.

VI. RESULTADOS

TABLA I
RESULTADOS CUANTITATIVOS DEL PROTOTIPO

Indicador	Casos	Resultado
<i>Evaluación automática</i>		
Salidas estructuralmente válidas	37/40	92,5 %
Decisión de estado correcta	35/40	87,5 %
Evidencia de referencia en top-5	31/33	93,9 %
Al menos una cita de referencia	27/33	81,8 %
Toda la evidencia esperada citada	25/33	75,8 %
Abstención en no respondibles	7/7	100 %
<i>Revisión humana</i>		
Corrección factual estricta	26/33	78,8 %
Puntaje factual ponderado	28,5/33	86,4 %
Fidelidad total a fuentes	29/31	93,5 %
Cobertura completa	24/33	72,7 %
Conclusión aprobada	28/40	70,0 %
<i>Latencia promedio</i>		
Búsqueda semántica	40 consultas	27 ms
Generación local	37 salidas	5,36 s
Pipeline completo	40 consultas	5,53 s

Nota: Las métricas de recuperación y citas utilizan las 33 preguntas respondibles. La fidelidad excluye nueve casos sin afirmaciones evaluables. La generación concentró la mayor parte de la latencia total.



El sistema resolvió mejor las preguntas directas y las abstenciones. La menor aprobación en preguntas multisección indica que la presencia de alguna evidencia pertinente no garantiza cobertura completa.

VII. DISCUSIÓN: VALOR DE LA OBSERVABILIDAD

1) Evidencia distribuida. Solo 2 de 8 preguntas multisección fueron aprobadas. En varios casos se recuperó una parte de la evidencia, pero no todos los artículos necesarios.

2) Documento correcto, fragmento incorrecto. En q029 se recuperó el artículo relacionado, pero no el fragmento que contenía el dato. Una evaluación limitada al documento habría ocultado el fallo.

3) Contenido correcto, salida inválida. q025 y q032 se rechazaron porque las citas visibles y estructuradas no coincidían. La validez del contrato de salida constituye una dimensión adicional de calidad.

4) Abstención confiable. Las siete preguntas sobre información ausente recibieron `not_found`, sin producir afirmaciones no respaldadas.

VIII. LIMITACIONES Y TRABAJO FUTURO

El estudio utiliza un único dominio documental, un modelo de embeddings, un modelo generativo, 40 preguntas y una persona revisora. Tampoco compara recuperación léxica, híbrida o con reranking; por tanto, los resultados no representan toda la diversidad del español latinoamericano.

El trabajo futuro evaluará reranking para evidencia multisección, recuperación densa frente a alternativas léxicas e híbridas, nuevos dominios y países, y umbrales de abstención con revisión humana adicional.

IX. CONCLUSIÓN

Una arquitectura RAG pequeña puede proporcionar trazabilidad útil sin requerir una plataforma de observabilidad compleja.

La conservación de evidencia, citas, estados y tiempos permitió diferenciar fallos de recuperación, generación y validación. El principal reto no fue la abstención, sino la cobertura de evidencia distribuida. En consecuencia, una arquitectura observable debe distinguir documentos de fragmentos y validar la consistencia de las citas antes de entregar la respuesta.