

Diseño arquitectónico mínimo para sistemas RAG observables en español latinoamericano

Nicole Tatiana Parra Valverde

Trabajo independiente

Caso de estudio: normativa estudiantil del Tecnológico de Costa Rica

Una arquitectura RAG mínima puede hacerse observable al conservar los artefactos necesarios para reconstruir y diagnosticar cada consulta.

I. PROBLEMA Y OBJETIVO

Problema—Los sistemas RAG incorporan evidencia recuperada al contexto de un modelo generativo [1]. Sin embargo, observar únicamente la respuesta final no permite determinar si un fallo se originó en la recuperación del contexto, la generación o la validación de la salida.

Propuesta—Se diseñó e implementó una arquitectura RAG mínima y reproducible que registra, para cada consulta, la configuración, los fragmentos recuperados y sus puntuaciones, el contexto, la respuesta, el estado, las citas y los tiempos.

Objetivo—Evaluar si estos artefactos permiten reconstruir cada ejecución y distinguir fallos de recuperación, cobertura, generación y validación.




Fig. 1. Indexación reproducible del corpus. Los documentos oficiales se transforman en secciones, fragmentos y representaciones vectoriales normalizadas antes de construir el índice local.

II. CORPUS E INDEXACIÓN

25 documentos oficiales
1 184 secciones procesadas
1 259 fragmentos indexados

El corpus reúne normativa estudiantil publicada por el Tecnológico de Costa Rica [2]. Cada captura conserva la URL oficial, la fecha de recolección y una suma SHA-256. Las secciones extensas se dividieron en fragmentos de hasta 480 tokens, con un solapamiento de 50.

III. PROTOCOLO DE EVALUACIÓN

25 directas
8 multisección
7 no respondibles

Se definieron 40 preguntas de referencia: 25 directas, 8 que requieren evidencia de varias secciones y 7 no respondibles con el corpus.

La evaluación combinó métricas automáticas de recuperación, citas, estructura y latencia con revisión humana de corrección factual, cobertura, fidelidad a las fuentes y conclusión global.

Nota: las métricas de recuperación y citas se calculan sobre las 33 preguntas respondibles.

ARTEFACTOS CONSERVADOS POR CONSULTA

Configuración Corpus, índice, modelos y parámetros utilizados.	Recuperación Fragmentos, identificadores, orden, puntuaciones y fuentes oficiales.
Generación Contexto proporcionado, respuesta, tokens y latencia.	Resultado Estado, validez estructural, citas verificadas y fuentes citadas.

Cada consulta produce un registro JSON que permite examinar posteriormente sus entradas, decisiones intermedias y salida sin repetir la ejecución.

La traza es un artefacto diagnóstico; no constituye por sí sola una métrica de calidad.

LIMITACIONES Y TRABAJO FUTURO

Limitaciones—El estudio utiliza un único dominio documental costarricense, un modelo de embeddings, un modelo generativo, recuperación densa, 40 preguntas y una persona revisora. Por tanto, los resultados no representan toda la diversidad documental y lingüística del español latinoamericano.

Trabajo futuro—Se evaluarán recuperación léxica e híbrida, reranking para evidencia distribuida, nuevos dominios latinoamericanos y revisión humana adicional.

IV. ARQUITECTURA RAG OBSERVABLE




Fig. 2. Flujo observable de consulta y generación. El orquestador coordina la codificación de la pregunta, la recuperación del contexto, la generación local y la validación, mientras conserva los artefactos producidos en cada etapa.


Traza por consulta = configuración + recuperación + generación + resultado

Configuración: multilingual-e5-small [3]; 384 dimensiones; similitud coseno; top-5; Qwen3.5:9B; Ollama; temperatura 0,1.

V. RESULTADOS: ¿QUÉ PERMITIÓ OBSERVAR LA ARQUITECTURA?

93,9 % Evidencia recuperada 31/33 preguntas respondibles recuperaron alguna evidencia de referencia en el top-5.	70,0 % Conclusión aprobada 28/40 salidas obtuvieron una conclusión global aprobada mediante revisión manual.
25,0 % Preguntas multisección 2/8 preguntas que requerían evidencia de varias secciones fueron aprobadas.	100 % Abstención correcta Las 7 preguntas no respondibles produjeron una abstención correcta.

Hallazgo principal—Recuperar alguna evidencia pertinente no garantiza reunir toda la información necesaria. Aunque 31 de 33 preguntas respondibles recuperaron evidencia de referencia, solo 2 de 8 preguntas multisección fueron aprobadas.



Indicador secundario	Casos	Resultado
Salidas estructuralmente válidas	37/40	92,5 %
Decisión de estado correcta	35/40	87,5 %
Al menos una fuente de referencia citada	27/33	81,8 %
Toda la evidencia esperada citada	25/33	75,8 %
Fidelidad total a las fuentes	29/31	93,5 %
Tiempo promedio del pipeline	40 consultas	5,53 s

Nota: las métricas de recuperación y citas utilizan 33 preguntas respondibles. La fidelidad se calculó sobre 31 respuestas con afirmaciones evaluables. Los porcentajes no constituyen una medida única de exactitud general.

CONCLUSIÓN

Una arquitectura RAG mínima puede ofrecer observabilidad útil sin depender de una plataforma compleja.

Al conservar fragmentos, puntuaciones, contexto, respuesta, estado, citas y tiempos, el prototipo permitió distinguir fallos de recuperación, cobertura, generación y validación. En el caso estudiado, el principal reto fue reunir evidencia distribuida entre varias secciones, no abstenerse ante información ausente.



github.com/niparra21/nlpArgentina

VI. LECCIONES ARQUITECTÓNICAS

Evidencia distribuida Las preguntas multisección obtuvieron la menor aprobación: 2/8. En varios casos se recuperó solo una parte de la evidencia. <i>Implicación:</i> Evaluar cobertura conjunta, no solo la presencia de un documento relacionado.	Documento correcto, fragmento incorrecto La traza reveló casos en los que se recuperó el documento pertinente, pero no el fragmento que contenía el dato. <i>Implicación:</i> Conservar identificadores, orden y puntuaciones a nivel de fragmento.	Validación independiente Dos salidas con contenido pertinente fueron rechazadas porque las citas visibles y los identificadores estructurados no coincidían. <i>Implicación:</i> Validar tanto el contrato JSON como la consistencia de las citas.
--	--	---

VII. Referencias

- P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W. tau Yih, T. Rocktäschel, S. Riedel, and D. Kiela, “Retrieval-augmented generation for knowledge-intensive nlp tasks,” in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 9459–9474.
- Tecnológico de Costa Rica, “Reglamentos y normativa institucional utilizados como corpus,” Sitio web institucional y captura reproducible del proyecto, 2026, corpus de 25 documentos; consultado y versionado en julio de 2026. [Online]. Available: <https://www.tec.ac.cr/>
- L. Wang, N. Yang, X. Huang, L. Yang, R. Majumder, and F. Wei, “Multilingual e5 text embeddings: A technical report,” *arXiv preprint arXiv:2402.05672*, 2024.

Los resultados corresponden a una corrida reproducible del prototipo y no sustituyen la consulta de la normativa oficial.